




自然語言處理與應用

Natural Language Processing and Applications

Mamba

Instructor: 林英嘉 (Ying-Jia Lin)
2026/05/25



GitHub



Slido
NLP0525
([Link](#))

Announcement

For Checkpoint3

Final Project 各個階段分數佔比

Final Project 佔學期總成績 30%

查核點 (週次)	對象: 繳交內容	分數佔比
Checkpoint3 (Week 15-16)	All teams: 最終口頭報告	10%
Checkpoint4 (Week 16-17)	All teams: 書面報告檔案	10%

Checkpoint 3 (for W15 / W16 oral)

- 一組至多 18 分鐘 (時間包括老師 QA 3分鐘)
 - 老師 QA：給建議為主，問問題為輔
- Week 15: 8組 (共約 144 分鐘)
- Week 16: 8組 (共約 144 分鐘)

Checkpoint 3 (for W15 / W16 oral)

- Checkpoint 3 有兩種 deadlines:

作業名稱	正體中文 期末專案checkpoint3	填寫更多語言	最少要填寫 其中一種語 言，每種語 言限填 254 字元
作答說明/師長叮嚀	每組上傳1份即可 Week15 上傳時間：2026/06/01 11:59 a.m. Week16 上傳時間：2026/06/08 11:59 a.m.		顯示於進入 作業前一頁

- 這是 hard deadlines，老師會於上課前將各組的檔案準備至講桌電腦以節省時間

Week 15 / Week 16 之前要繳交什麼？

- 一組繳交一份，請上傳至 E-Learning
- 檔名：NLP_teamN_checkpoint3.pdf 與 NLP_teamN_checkpoint3.pptx (both pdf & pptx)
 - (Optional) NLP_teamN_checkpoint3_oral.pdf 與 NLP_teamN_checkpoint3_oral.pptx
- 前11頁 (含首頁)：Checkpoint1+Checkpoint2 原始簡報內容 (如有需要，可修改)
 - (如果你們組別本來頁數就很多，那可能不只 11 頁)
- 後5頁 (或更多)：加入新進度
 1. 實作的方法介紹 (代表各組**須完成完整實作**)，可以包含：
 - 資料前處理、模型介紹、訓練策略 (如 loss function 設計、模型訓練組合等) 等...
 2. 實驗結果比較 (含實驗設定說明)：
 - 需要有 (1) 不同模型之間 (2) 不同 **checkpoints** 之間 (3) (如果有) 其他 **code** 的比較
 3. Kaggle Leaderboard 名次或分數 (請截圖貼到簡報中)
 4. 時程規劃 (再來還要簡單測試什麼？用表格列出未來 1-2 週內的可能測試與安排)
 5. 針對 **Checkpoint3** 之前的小組分工細節，置於最後一頁

Outline


- Mamba [85 min]
- Quiz [15 min]
- Presentations [50 min]

Problems of Transformer

- Quadratic scaling with respect to the window length


[Recap] Self-Attention (Transformer) 過程

Vaswani et al. "Attention is all you need." NeurIPS 2017.
<https://research.google/blog/transformer-a-novel-neural-network-architecture-for-language-understanding/>



[Recap] Self-Attention (Transformer) 過程

Vaswani et al. "Attention is all you need." NeurIPS 2017.
<https://research.google/blog/transformer-a-novel-neural-network-architecture-for-language-understanding/>



(For simplicity, I only draw the self-attention process for the second token.)

Problems of Transformer


- Quadratic scaling with respect to the window length
 - attention 要算「每個 token 對每個 token」，假設一序列長度為 L
 - token 1 要對 L 個 token 各算一個分數 $\rightarrow L$ 次
 - token 2 也要對 L 個 token 各算一次 $\rightarrow L$ 次
 - ...
 - token L 同樣 $\rightarrow L$ 次

[Recap] 為什麼 Transformers 可以平行化？

d_k : queries 和 keys 的維度大小


通常設置 $d_q = d_k = d_v$

Scaled Dot-Product Attention



$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

(自注意力機制可以利用矩陣乘積來進行平行化計算)



Transformer 計算量為 $O(L^2)$

12. (7%) 假設輸入序列長度為 n ，在 Self-Attention 中，單一 token 的 Query 向量和單一 token 的 Key 向量進行點積運算後會得到一個 Attention Score（純量），但實際上所有 token 的 Query 和 Key 會以矩陣的形式進行點積運算，得到一個 Attention Score 矩陣。請問該 Attention Score 矩陣的形狀為？ 答案為 $N \times N$

請一併說明矩陣中任意第 i 個 row 和第 j 個 column 的數值代表什麼意義。

(忽略 batch 與 multi-head，只考慮單一序列的 self-attention。)

- 長度為 1k $\rightarrow$ 計算 1 百萬次得到 Attention score matrix
- 長度為 2k $\rightarrow$ 計算 4 百萬次得到 Attention score matrix

Linear-Time Sequence Modeling with Selective State Spaces

Albert Gu¹, Tri Dao²

¹Machine Learning Department, Carnegie Mellon University and

²Department of Computer Science, Princeton University

Conference on Language Modeling (COLM), 2024

Terminology

- S4: 基本的 state space model
- S6: Mamba，沿用 S4 的概念，但是 SSM 會依據不同 token 位置而有不同 ➡
time-variant，也就是 **Selective** State Space Model

什麼是 State Space Models (SSM)? (0)


- State Space Models 源於控制理論，離散化後的遞迴形式如下

$$h_t = Uh_{t-1} + Wx_t$$

- 「state space」指的是「那個狀態變數 h 所有可能取值構成的空間」——是系統內部記憶的狀態空間
- RNN 若扣除非線性轉換，廣義上是一種 SSM
 - 因為 S4 (Mamba 前身) 中的 SSM 被設計為可平行化，

什麼是 State Space Models (SSM)? (1)

RNN Recap




假設 shape

$x_n : (1, 512)$, t 代表輸入序列位置 (token index)

$W : (512, 768)$ ➡ 相當於 W 在高維度空間中處理 x_n 的資訊

什麼是 State Space Models (SSM)? (2)

假設 $\text{shape } x_n : (1, D)$




- ➡ 有 D 個不同的 SSMs 在個別處理 x_n 的資訊
- ⚠ 注意：input 跟 output 都是 scalar
- ➡ 在 embedding 空間中再劃出隱藏空間

S4 中的 SSM

假設 shape $x_n : (1, D)$


第 n 個 token
的 hidden state



每個維度都有一個獨立的 SSM

- Transformer (multi-head attention) 也有類似的過程


State Space Model: Each dimension is managed by an independent state space model!



Output

Input

Transformer: Each group of dimensions is managed by a different head of the multi-head attention!



State Space Models (SSM)

Structured State space models (S4)

Differential Equation!

$$h'(t) = Ah(t) + Bx(t) \quad (1a)$$

$$y(t) = Ch(t) \quad (1b)$$

符號	意義	Time-variant?
$x(t)$	Inputs	✓
$h(t)$	Hidden state	✓
$h'(t)$	Hidden state 改變量	✓
A	Memory Gate	✗
B	Input Gate	✗
C	Output Gate	✗

Differential Equation (t 以 token 為單位)

透過 zero-order hold (ZOH)
進行離散化

$$\begin{array}{ll} h'(t) = Ah(t) + Bx(t) & (1a) \\ y(t) = Ch(t) & (1b) \end{array} \xrightarrow{\text{ZOH}} \boxed{\begin{array}{ll} h_t = \bar{A}h_{t-1} + \bar{B}x_t & (2a) \\ y_t = Ch_t & (2b) \end{array}}$$


離散化 (Discretization) 簡單推導

https://www.youtube.com/watch?v=8Q_tqwpTpVU&t=602s

SSM 的好處？全域卷積

我們已經發現 SSM 是 RNN

然而，RNN 的問題：無法平行化



SSM 的好處？全域卷積

$$h_t = \bar{A}h_{t-1} + \bar{B}x_t \quad (2a)$$

$$y_t = Ch_t \quad (2b)$$

$$y_0 = Ch_0 = C(\bar{A}h_{-1} + \bar{B}x_0) = C\bar{B}x_0 = C\bar{A}^0\bar{B}x_0$$

$$h_0 = \bar{A}^0\bar{B}x_0$$

$$y_1 = Ch_1 = C(\bar{A}h_0 + \bar{B}x_1) = C(\bar{A}\bar{A}^0\bar{B}x_0 + \bar{B}x_1) = C(\bar{A}^1\bar{B}x_0 + \bar{A}^0\bar{B}x_1)$$

$$h_1 = \bar{A}^1\bar{B}x_0 + \bar{A}^0\bar{B}x_1$$

$$y_2 = Ch_2 = C(\bar{A}h_1 + \bar{B}x_2) = C(\bar{A}(\bar{A}^1\bar{B}x_0 + \bar{A}^0\bar{B}x_1) + \bar{B}x_2)$$

$$= C(\bar{A}^2\bar{B}x_0 + \bar{A}^1\bar{B}x_1 + \bar{B}x_2)$$

$$= C(\bar{A}^2\bar{B}x_0 + \bar{A}^1\bar{B}x_1 + \bar{A}^0\bar{B}x_2)$$

$$h_2 = \bar{A}^2\bar{B}x_0 + \bar{A}^1\bar{B}x_1 + \bar{A}^0\bar{B}x_2$$

找到規律 ➡

$$h_n = \bar{A}^n\bar{B}x_0 + \bar{A}^{n-1}\bar{B}x_1 + \cdots + \bar{A}^0\bar{B}x_n$$

SSM 的好處？全域卷積 (以 y_2 為例)

$$y_2 = Ch_2 = C(\bar{A}h_1 + \bar{B}x_2) = C(\bar{A}^2\bar{B}x_0 + \bar{A}^1\bar{B}x_1 + \bar{A}^0\bar{B}x_2)$$

$$\begin{array}{c} [x_0 \quad x_1 \quad x_2] * \begin{bmatrix} C\bar{A}^2\bar{B} \\ C\bar{A}^1\bar{B} \\ C\bar{A}^0\bar{B} \end{bmatrix} \\ \text{輸入序列} \qquad \qquad \qquad \text{卷積核} \end{array}$$

💡 代表在 $\bar{A}$ 和 $\bar{B}$ 不隨時間變動的情況下，輸入 $x_0, x_1, \dots, x_n$ 的序列，SSM 其實還是能夠平行化


更多卷積的想像

[https://github.com/hkproj/mamba-
notes/blob/main/Mamba_Slides.pdf](https://github.com/hkproj/mamba-notes/blob/main/Mamba_Slides.pdf)

- P.16 – P.20

S4 的 SSM 流程 overview

假設 shape $x_t : (1, D)$




- ➡ 有 D 個 SSMs 在個別處理 x_n 的資訊
- ⚠ 注意：input 跟 output 都是 scalar
- ➡ 在 embedding 空間中再劃出隱藏空間

S4 的 SSM 流程：維度變化

假設 shape $x_n : (1, D)$

任一個 SSM 內部在做的事情：



$$h_t = \bar{A} h_{t-1} + \bar{B} x_{n,t}$$

Dimensions: $N \times N$ for $\bar{A}$, $N \times 1$ for h_{t-1} , $N \times 1$ for $\bar{B}$, and 1×1 for $x_{n,t}$.

$$y_{n,t} = C h_t$$


Dimensions: $1 \times N$ for C and $N \times 1$ for h_t .

⚠ S4 的問題：SSM 有 D 個，但沒有 n 個

S4 的問題：不同的 n 共享相同的 SSMs

假設 shape $x_n: (1, D)$


第 n 個 token
的 hidden state



S4 的問題：不同的 n 共享相同的 SSMs

假設 shape $x_{n+1}: (1, D)$

第 $n+1$ 個 token
的 hidden state




沒有 n 個 SSMs

代表 SSM 不會隨著文字
資訊變化 (time-invariant)



SSM₀ SSM₁ SSM₂ SSM₃ SSM₄ SSM_{D-5} SSM_{D-4} SSM_{D-3} SSM_{D-2} SSM_{D-1}

x_{n+1}



t

0

1

2

3

4

...

$D-5$

$D-4$

$D-3$


$D-2$

$D-1$

Mamba 的解決方案：改成 $n \times D$ 組 SSMs

假設 shape x_n : (1, D)

第 n 個 token
的 hidden state



相較於 S4，Mamba 不能用全域卷積

SSM (S4): Time invariant

$$h_t = \bar{A}h_{t-1} + \bar{B}x_t \quad (2a)$$

$$y_t = Ch_t \quad (2b)$$

$$y_0 = C\bar{B}x_0$$

$$y_1 = C(\bar{A}^1\bar{B}x_0 + \bar{A}^0\bar{B}x_1)$$

$$y_2 = C(\bar{A}^2\bar{B}x_0 + \bar{A}^1\bar{B}x_1 + \bar{A}^0\bar{B}x_2) \quad \rightarrow \text{可以找到規律} \text{💡}$$

Mamba (S6): Time variant 所以 $\bar{A}, \bar{B}, C$ 要加下標

$$y_0 = C_0h_0 = C_0\bar{B}_0x_0$$

$$y_1 = C_1h_1 = C_1(\bar{A}_1h_0 + \bar{B}_1x_1) = C_1(\bar{A}_1\bar{B}_0x_0 + \bar{B}_1x_1)$$

$$y_2 = C_2h_2 = C_2(\bar{A}_2h_1 + \bar{B}_2x_2) = C_2(\bar{A}_2\bar{A}_1\bar{B}_0x_0 + \bar{A}_2\bar{B}_1x_1 + \bar{B}_2x_2) \quad \rightarrow \text{不存在一個固定的卷積核！}$$

Mamba 加速策略：Prefix Sum

Array

START				END
2	4	6	8	10

Prefix Sum

2	6	12	20	30
---	---	----	----	----

好處：不用每次都從頭加到尾

Mamba 使用的 Parallel Scan


核心概念：結合律 $A*B*C*D = \underline{(A*B)}*\underline{(C*D)}$

$A*B$ 和 $C*D$ 同時進行

$$y_0 = C_0 h_0 = C_0 \bar{B}_0 x_0$$

$$y_1 = C_1 h_1 = C_1 (\bar{A}_1 h_0 + \bar{B}_1 x_1) = C_1 (\bar{A}_1 \bar{B}_0 x_0 + \bar{B}_1 x_1)$$

$$y_2 = C_2 h_2 = C_2 (\bar{A}_2 h_1 + \bar{B}_2 x_2) = C_2 (\bar{A}_2 \bar{A}_1 \bar{B}_0 x_0 + \bar{A}_2 \bar{B}_1 x_1 + \bar{B}_2 x_2)$$



Original: 3 steps

Parallel Scan: 2 steps

SRAM vs. HBM

- SRAM: Static Random-Access Memory (靜態隨機存取記憶體)
- HBM: High Bandwidth Memory (高頻寬記憶體)
- DRAM: Dynamic Random-Access Memory (動態隨機存取記憶體)




Figure source: <https://www.digitalocean.com/community/tutorials/flashattention>


硬體加速

Step 1:輸入 tensors 在主記憶體，先搬至 HBM

Step 2:計算前將 tensors 移至 SRAM，進行離散化、遞迴

Step 3:輸出再移至 HBM 進行計算 ($y_t = C_t h_t$)

Mamba Overview



Results: Speed comparisons






Figure 8: (**Efficiency Benchmarks.**) (*Left*) Training: our efficient scan is $40\times$ faster than a standard implementation. (*Right*) Inference: as a recurrent model, Mamba can achieve $5\times$ higher throughput than Transformers.

Results: Perplexity on different model scales



Conclusion

- Mamba (S6) 藉由 selective SSM 機制，取得了與 Transformer 架構相當的準確性，但速度更快
- Mamba 無法像 S4 那樣透過全域卷積來平行化，但其外加了 parallel scan，搭配於 SRAM 中執行遞迴的設計，降低了其計算所需的時間

Additional Links

<https://huggingface.co/blog/lbourdois/get-on-the-ssm-train>

SSM by Albert Gu

- <https://youtu.be/OpJMn8T7Z34?si=uD69Lz8Kn142mdrU>

Euler's Method Differential Equations

- <https://youtu.be/ukNbG7muKho?si=HTn56tZZ2eqfMRap>

Thank you!

Instructor: 林英嘉

 yjlin@cgu.edu.tw

TA: 林宣辰

 b1128015@cgu.edu.tw